

Buscador Plenario Inteligente — Dossier técnico (mi parte)

IDAL · Reto 2 — Generación del acta a partir del vídeo del pleno

- > Documento de estudio para la reunión con el profesor. Cubre **mi parte**: convertir el vídeo
- > de un pleno en un acta formal, buscable y verificable, **sin necesitar un acta oficial previa**.
- > (Las otras partes —búsqueda de actas oficiales y modo ciudadano/KPIs— las llevan mis compañeros.)

1. El problema y la solución

Problema. Muchos ayuntamientos no pueden pagar una transcripción profesional de sus plenos. El pleno queda grabado en vídeo (YouTube), pero **sin acta buscable**: nadie puede consultar qué se dijo, quién lo dijo ni qué se votó sin verse horas de vídeo.

Solución. A partir de un **enlace de YouTube** generamos automáticamente:

1. La **transcripción** completa (voz a texto), buscable.
2. Un **acta formal** con el estilo del *Diario de Sesiones* (PDF + texto): asistentes, orden del día, estadísticas, desarrollo por puntos y votaciones.
3. Un **visor sincronizado** acta↔vídeo (clic en una frase → salta a ese momento).

Todo **en local** (sin enviar datos a la nube ni pagar por API) y **a ciegas** (sin un acta oficial de referencia; esa solo la usamos para *calibrar* contra el Congreso, que sí publica Diarios).

2. Arquitectura — el pipeline

`

Enlace YouTube

■ (yt-dlp + Deno)

▼

[A] DESCARGA ■■■ audio (.m4a/.wav) + vídeo (.mp4)

■

▼

[B] TRANSCRIPCIÓN (ASR) faster-whisper large-v3-turbo (int8, GPU)

■ · VAD (corta silencios) · multilingüe (valencià/castellà)

▼

[C] DIARIZACIÓN (¿quién habla?) pyannote 3.1 → clusters de voz + solapamientos

■ · fusión de voces (ECAPA) + absorción de clusters fantasma

▼

[D] NOMBRADO anuncios ("tiene la palabra...") + NER + roster

■ (en municipal: "Voz N" → etiquetado humano 1 vez)



[E] CORRECCIÓN LÉXICA (lexfix) términos locales contra glosario (fonético)



[F] ACTA (estilo Diario de Sesiones) reportlab → PDF + texto

■ · orden del día (convocatoria, vía LLM) · estadísticas · votaciones

■■■■■ [G] VISOR sincronizado acta↔vídeo (FastAPI /sync)

■■■■■ [H] VOTACIONES POR VISIÓN (integración): YOLO-pose cuenta manos



Bucle que mejora solo (self-improving): al etiquetar las voces una vez, se guarda una *huella de voz* del orador; en el **siguiente** pleno del mismo ayuntamiento esa voz se reconoce sola.



3. Cada bloque en detalle

[A] Descarga

- **yt-dlp** (descargador) + **Deno** (runtime JS para resolver el nsig de YouTube).
- Audio para la transcripción; vídeo (≤480p) para el visor y la visión.
- *Decisión*: para plenos largos se pueden bajar **solo los tramos** necesarios (--download-sections), no el vídeo entero.

[B] Transcripción (ASR — Automatic Speech Recognition)

- **faster-whisper** con el modelo **large-v3-turbo** en **int8** (entra en 4 GB de VRAM).
- **VAD** (*Voice Activity Detection*): recorta silencios y trocea en pausas → evita que Whisper "se salte" texto en tramos largos de habla rápida.
- **multilingual=True**: detecta el idioma **por fragmento** → imprescindible en plenos bilingües (valencià/castellà). Forzar "es" destrozaba el valenciano ("L'esmena" → "La semana").
- **word_timestamps**: tiempos por palabra (los usa la votación por visión para saber el instante exacto de "¿votos a favor?").

[C] Diarización (¿quién habla?)

- **pyannote-audio 3.1**: segmenta el audio en *clusters* de voz (SPEAKER_00, 01...).
- **Solapamiento (cruce)**: marca los tramos donde hablan dos a la vez (discusión) y los excluye de las huellas de voz.
- **Fusión / absorción**: une clusters que son la misma persona (coseno de huella ECAPA) y absorbe clusters "fantasma" diminutos nacidos del cruce → arregla el "Voz 4 que en realidad es Voz 3".

[D] Nombrado (¿quién dijo qué?)

- **Anuncios**: detecta "tiene la palabra el señor X" + **NER** (reconocimiento de entidades) + casado

con el **roster** (lista de concejales). Funciona bien en el Congreso (anuncios formales).

- **En municipal** apenas hay anuncios → las voces salen como **"Voz N"** y el secretario las etiqueta **una sola vez** (escucha una muestra, pone el nombre). *No recomendamos nombre/cargo a ciegas* (falla mucho); solo la **huella de voz** ofrece una sugerencia fiable de un clic.

[E] Corrección léxica (lexfix)

- El ASR ya está cerca del techo, pero falla en **términos locales** ("mancomunidad" → "bancomunidad").
- Ningún ajuste de Whisper lo arregla (probado prompt, hotwords, modelo grande).
- **lexfix** corrige por **similitud fonética** contra un glosario cerrado del municipio (sin regex de clasificación): conservador, no toca palabras correctas ni inventa.

[F] Acta (estilo Diario de Sesiones)

- **reportlab** genera el PDF (calco del Diario nuevo del Congreso: membrete, una columna, versalitas).
- **Orden del día:** los puntos salen de la **convocatoria** (PDF) → un **LLM** local extrae los títulos oficiales exactos. Si no hay convocatoria, se detectan por el habla ("punto número uno").
- **Estadísticas:** tiempo por orador y por partido. **Asistentes:** oradores + intervenciones.
- **Tiempos enlazados al vídeo** (clic en el minuto → YouTube en ese segundo).

[G] Visor sincronizado

- **FastAPI** sirve /sync: vídeo de YouTube (IFrame API) + transcripción que se resalta sola; clic en una frase salta al vídeo. Para verificar el acta contra la grabación.

[H] Votaciones por visión (integración con la parte del compañero)

- **YOLO11-pose** (ultralytics) detecta manos levantadas y cuenta a favor / en contra / abstención.
- Se dispara con **nuestros tiempos** (las ventanas de cada votación salen de la transcripción con *word-timestamps*). El recuento se coloca en su punto del acta; los fotogramas con el **esqueleto** de pose sirven de prueba visual.

4. Stack tecnológico (qué y por qué)

Tecnología	Para qué	Por qué esta
faster-whisper (large-v3-turbo, int8)	Transcripción (ASR)	5× más rápido que large-v3, calidad casi igual; int8 entra en 4 GB
pyannote-audio 3.1	Diarización (quién habla)	Estándar de facto en separación de locutores
ECAPA-TDNN (speechbrain)	Huella de voz (192-d)	Reconocer al mismo orador entre plenos (self-improving)
BGE-M3 (sentence-transformers)	<i>Embeddings</i> semánticos	Búsqueda por significado y comparación de actas; multilingüe
Transformers (NER)	Nombres en los anuncios	Extraer entidades de persona del habla
Ollama + qwen2.5:3b	LLM local	Resúmenes neutrales y extracción del orden del día de la convocatoria; cabe en 4 GB

Tecnología	Para qué	Por qué esta
YOLO11-pose (ultralytics)	Votaciones por visión	Contar manos levantadas a mano alzada
reportlab + PyMuPDF	Acta PDF / render	Documento formal estilo Diario de Sesiones
FastAPI + Tailwind + YouTube IFrame	Interfaz (Bloque D)	UI moderna; visor con vídeo incrustado
yt-dlp + Deno	Descarga de YouTube	Resolver el anti-bot de YouTube (nsig)

Hardware: todo corre en una **RTX 3050 Laptop (4 GB VRAM)** → coste cero por transcripción, dato local (clave para RGPD y para el argumento "municipios sin presupuesto").

5. Validadores y métricas (cómo sabemos que funciona)

- > Idea central: el *Diario de Sesiones* oficial **no es literal** (edita el habla), así que el WER
- > crudo contra él no sirve. Medimos con las herramientas adecuadas a cada cosa.

Qué medimos	Herramienta	Resultado
Precisión del ASR (palabra a palabra)	<code>scripts/eval_goldset.py</code> (vs <i>gold set</i> verbatim hecho a mano, 5 min de Chiva, 693 palabras)	WER 4,3% → ~96% de acierto (3,9% con lexfix)
Por qué no WER vs Diario	<code>scripts/eval_asr.py</code>	En 208 min solo hay ~5 tramos literales → no medible; lo demostramos
¿Detecta que es la MISMA voz?	<code>scripts/eval_voice.py</code> (cluster ↔ orador oficial)	Consistencia 22/22 = 100% (biunívoco) en PL-161
Acierto de NOMBRE (de los anuncios)	<code>scripts/compare_diario.py</code>	87% — pero el nombre lo confirma el humano 1 vez; lo que importa es la voz (100%)
Parecido end-to-end vs Diario oficial	<code>scripts/compare_diario.py</code> (PL-161, pleno de 3,5 h, a ciegas)	90,8% · cobertura 100% · fidelidad 0,89 · tema 87% · votaciones 4/4
Reconocimiento de voz entre sesiones	<code>src/voiceid.py</code> (2 plenos de Chiva)	5 de 6 voces reconocidas (sim 0,81–0,92); la 6ª, nueva, rechazada (open-set: nunca inventa)
Votaciones por visión	<code>src/vote_detect.py</code> (Chiva)	Sentido correcto ("aprobado por mayoría"); conteo aproximado (vídeo a 360p)
Bilingüe	Lliria (pleno en valencià, 2,5 h)	valencià y castellà transcritos cada uno en su idioma

Cómo leer los números clave (para el profesor):

- **96%** de transcripción sobre audio real, validado contra transcripción humana.
- **Separación de voz 100%** (cada persona = una voz, uno a uno): etiquetando una vez → atribución perfecta y reutilizable. El "87%" es solo el adivina-nombres automático, que el producto **no usa**.
- **90,8%** de parecido con el Diario oficial del Gobierno, **a ciegas**, en un pleno de 3,5 h.

6. Decisiones de diseño (y su porqué)

1. **A ciegas** (sin acta oficial): es el caso real del municipio. El Diario solo se usa para *calibrar*.
2. **NER/embeddings/LLM, nunca regex** para clasificar/extraer (más robusto y mantenible).

3. **lexfix posterior**, no afinar Whisper: el ASR está en el techo; los términos locales se arreglan con un glosario, no reentrenando.
4. **Multilingüe por fragmento**: forzar "es" rompe el valenciano.
5. **Etiquetado humano 1 vez + reuso de huella** en lugar de auto-nombrado: el auto-nombrado es propio del Congreso (anuncios) y falla en municipal; la voz sí es fiable y mejora sola.
6. **RGPD desde el diseño**: el dato es local; la huella se guarda **con consentimiento** (casilla "Guardar voz", opt-out) y hay **aviso de transparencia**. Base: cargos públicos / publicidad de los plenos. No se aplica al público.
7. **Solo clips para la visión**: no descargar plenos de 5 h enteros.

7. Limitaciones honestas (mejor decirlas tú antes que las pregunten)

- **Conteo de votos**: el vídeo de Chiva en YouTube es 360p → infracuenta (detecta ~5–6 de ~9). El **sentido** (aprobado/mayoría) es correcto. Con vídeo en HD sería exacto.
- **Solapamiento (cruce de voces)**: cuando hablan a la vez, la atribución puede fallar; lo marcamos como "(cruce de intervenciones)". Es inherente a la diarización.
- **Orden del día automático** (sin convocatoria): los títulos salen aproximados → por eso usamos la convocatoria oficial (PDF → LLM) cuando se aporta.
- **Nombres**: a ciegas no se "saben"; se confirman una vez (humano) o por huella.

8. Preguntas probables del profesor (y respuestas)

- **"¿No es esto solo Whisper?"** → No. Whisper es solo el bloque A. El valor está en hacerlo ****a ciegas y formal****: diarización + identidad de voz reutilizable + acta estilo Diario + votaciones por visión + validación. Y todo **local** (RGPD, coste cero).
- **"¿Cómo sabéis que funciona si no hay acta?"** → Calibramos contra el ****Diario oficial del Congreso (90,8%) y contra un gold set verbatim**** hecho a mano (96%).
- **"¿Y si se equivoca con un nombre?"** → La **voz** es 100% consistente; el nombre lo confirma el secretario **una vez** y queda bien en todas sus intervenciones (y para los próximos plenos).
- **"¿Datos personales / RGPD?"** → Local, con consentimiento por persona (opt-out), aviso de transparencia, cargos públicos. (El DPD de Chiva confirmó que basta el aviso, sin firma.)
- **"¿Escala a plenos largos?"** → Sí: validado en uno de 3,5 h (Congreso) y 2,5 h (Lliria).
- **"¿Qué os diferencia del resto?"** → Acta verbatim + identidad de voz reutilizable + ****votaciones leídas por visión**** (ni la videoacta oficial de Lliria transcribe el debate: solo enlaza al vídeo).

9. Glosario

- **ASR**: transcripción automática del habla (voz → texto).
- **VAD**: detección de actividad de voz (separa habla de silencio).
- **Diarización**: dividir el audio por *quién* habla (sin saber el nombre).
- **Huella de voz / embedding de locutor (ECAPA)**: vector que representa una voz; voces parecidas → vectores cercanos (coseno alto).
- **Embedding semántico (BGE-M3)**: vector que representa el *significado* de un texto.
- **NER**: reconocimiento de entidades nombradas (personas, organizaciones...).
- **WER** (*Word Error Rate*): % de palabras mal transcritas frente a una referencia.
- **Open-set**: el sistema admite que una voz sea de alguien **nuevo** y no fuerza un nombre.
- **Pose / keypoints (YOLO-pose)**: esqueleto de articulaciones de cada persona en la imagen.
- **LLM**: modelo de lenguaje grande (aquí qwen2.5:3b, local vía Ollama).

ACTUALIZACIÓN (3 de julio de 2026)

Este dossier describe el sistema a 25 de junio. Desde entonces (ver pipeline_completo.pdf, el documento maestro actualizado):

- **Asignación supervisada por huella**: el registro de voces ya no solo sugiere nombres — corrige el clustering de la diarización (pureza 100 % medida, 0 falsos). La identidad sale solo del humano o de la huella consentida; el naming por anuncios quedó desactivado.
- **Validación externa nueva**: Ayuntamiento de **Madrid** (municipio real con Diario verbatim): 85,3 % de palabras literales a ciegas; media de 3 Diarios oficiales = 88 %.
- **Servidor GPU de la UV** (RTX 4060 Ti 16 GB): qwen2.5:14b vía túnel SSH con interruptor por variables de entorno; bake-off de 9 LLMs local+comercial.
- **Ampliación multimodal SEDIPUALBA completa** (pestaña Manuales): asistente sobre 12 manuales + 270 capturas descritas por visión + vídeo tutorial, con citas página/minuto (hit@6 = 87 %); y generador de **manuales ilustrados desde vídeos** con barrera anti-duplicados (validado a ciegas contra el manual oficial: 10/14 capítulos coinciden).
- **Buscador del Congreso v2**: consultas de evolución temporal por legislaturas.
- Operativa: arranque con un comando (arrancar_uv.ps1), auto-resurrección de servicios, alta de municipio en 1 comando, backfill del canal del ayuntamiento.
- **(4-5 de julio)** Pestaña **Alertas para vecinos**: suscripción a temas de catálogo cerrado (o a todos los plenos) con correo de citas literales + minuto de inicio + acta; detección semántica calibrada (umbral 0,57 medido), doble opt-in, vigilante del canal para el autopiloto. Y **5 mejoras en Manuales**: búsqueda por pantallazo (visión), diff entre versiones (validado con SEGEX v2), feedback de utilidad, respuestas en valencià y ficha PDF imprimible.