

# Estudio de costes por modelo y despliegue

Reto 2 · julio de 2026. Precios de API tomados **en vivo del catálogo de OpenRouter** (julio 2026) y tarifa publicada de la API de Whisper; el resto, medido en nuestro sistema. Conversión aplicada en los totales: 1 \$ ≈ 0,92 €. Se marca claramente qué es medido, qué es tarifa oficial y qué es estimación.

## 1. Supuestos de carga (municipio tipo)

| Magnitud                                     | Valor                                  | Origen                     |
|----------------------------------------------|----------------------------------------|----------------------------|
| Plenos al año                                | 24 (12 ordinarios + extraordinarios)   | estimación conservadora    |
| Duración por pleno                           | 3 h (180 min)                          | típico medido              |
| Transcript por pleno                         | ≈ 45.000 tokens                        | medido (≈30.000 palabras)  |
| Trabajo LLM por pleno (extracción, temas)    | ≈ 50.000 tokens entrada · 8.000 salida | medido en nuestro pipeline |
| Consultas al asistente de manuales           | 500/mes → 6.000/año                    | estimación                 |
| Por consulta de manuales                     | ≈ 6.000 tokens entrada · 600 salida    | medido (k=8 fragmentos)    |
| Capturas de manuales (visión, una única vez) | 330 imágenes hoy                       | medido                     |

## 2. Tarifas actuales (julio 2026)

| Modelo (API)                    | \$/M tokens entrada      | \$/M salida | Nota                                    |
|---------------------------------|--------------------------|-------------|-----------------------------------------|
| gpt-4o-mini                     | 0,15                     | 0,60        | gama económica                          |
| mistral-small-3.2-24b (alojado) | 0,075                    | 0,20        | el más barato del catálogo              |
| qwen-2.5-72b (alojado)          | 0,36                     | 0,40        | pariente grande de nuestro modelo local |
| claude-haiku-4.5                | 1,00                     | 5,00        | gama media                              |
| gemini-3.5-flash                | 1,50                     | 9,00        | el que usamos para VISIÓN               |
| claude-sonnet-5                 | 2,00                     | 10,00       | gama alta                               |
| gpt-5.2                         | 1,75                     | 14,00       | gama alta                               |
| ASR en nube (API Whisper)       | 0,006 \$/minuto de audio |             | la partida dominante                    |

## 3. Coste por pleno si todo fuera a la nube

- **Transcripción:** 180 min × 0,006 \$ = **1,08 \$ por pleno** — es la partida que manda, con cualquier LLM.
- **Trabajo LLM del pleno** (50k entrada + 8k salida): de **0,005 \$** (mistral-small alojado) a **0,20 \$** (gpt-5.2); gama media (haiku-4.5) ≈ 0,09 \$.
- **Total por pleno en nube:** ≈ **1,1-1,3 \$**.

## 4. Coste por consulta del asistente de manuales

| Vía                                       | Coste por consulta |
|-------------------------------------------|--------------------|
| Local (qwen 3b/7b/14b) — nuestra elección | <b>0 €</b>         |
| gpt-4o-mini                               | ≈ 0,0013 \$        |
| claude-haiku-4.5                          | ≈ 0,009 \$         |
| gemini-3.5-flash                          | ≈ 0,014 \$         |
| claude-sonnet-5 / gpt-5.2                 | ≈ 0,018-0,02 \$    |

## 5. La visión (lo único que sí compramos)

Descripción de capturas con gemini-3.5-flash: ≈ **0,45 céntimos de dólar por imagen** (≈1.200 tokens de imagen+prompt y 300 de salida). Nuestra ingesta completa (330 capturas) costó ≈ **1,5 \$ en total, una sola vez** — la caché por hash garantiza que ninguna imagen se paga dos veces. Un manual nuevo típico (~25 capturas) ≈ 0,11 \$. Un pantallazo de usuario: 0,45 c\$ la primera vez, gratis después.

## 6. Comparación anual (municipio tipo: 24 plenos + 6.000 consultas)

| Despliegue                                  | Año 1                                                                                   | Años siguientes                                    | Notas                                         |
|---------------------------------------------|-----------------------------------------------------------------------------------------|----------------------------------------------------|-----------------------------------------------|
| Todo local (nuestra elección)               | ≈ 300-450 € de GPU (una vez, si no hay equipo) + ~2 € de luz + 1,5 \$ de visión inicial | ≈ <b>2 €/año</b> (luz) + céntimos por manual nuevo | datos sin salir del ayuntamiento              |
| Todo nube, gama económica (4o-mini)         | ≈ 34 \$/año                                                                             | ≈ 34 \$/año                                        | ASR domina (26 \$); el dato viaja fuera       |
| Todo nube, gama media (haiku-4.5)           | ≈ 82 \$/año                                                                             | ≈ 82 \$/año                                        |                                               |
| Todo nube, gama alta (sonnet-5 / gpt-5.2)   | ≈ 140 \$/año                                                                            | ≈ 140 \$/año                                       |                                               |
| Videoacta comercial (referencia de mercado) | licencias anuales de 4 cifras                                                           | ídem                                               | estimación de mercado, por sesión o anualidad |

**A escala de 100 municipios:** la nube crece lineal (≈ 3.400-14.000 \$/año); el despliegue local no (cada consistorio corre lo suyo, coste marginal ~0).

## 7. Lectura honesta

Para **un** municipio, la nube no es cara (~30-140 \$/año). La elección local no se justifica solo por dinero, sino por cuatro razones en este orden:

- Soberanía del dato (RGPD):** el audio y las actas del pleno — con nombres de vecinos en ruegos y preguntas — no salen del equipo del ayuntamiento. Es la razón principal.
- Independencia:** sin dependencia de tarifas que cambian, cuotas, ni conexión a internet en el salón de plenos.
- Escala:** el modelo de producto es para muchos municipios; el coste nube escala lineal, el local es plano.
- Coste plano y previsible:** un ayuntamiento presupuesta una vez (hardware, si no lo tiene) y opera a coste cero — sin sorpresas por picos de uso.

La nube queda para lo único donde aporta algo que lo local no tiene: **visión** (describir capturas) — y ahí, con caché por hash, cada imagen se paga una única vez en la vida del sistema.

## 8. Dónde encaja el selector borroso

Estas cifras son las **entradas económicas** del selector de modelo (memoria técnica, §10): presupuesto y sensibilidad del dato se fuzzifican junto a la VRAM y la exigencia de calidad, y el sistema recomienda el despliegue idóneo por municipio — incluida la degradación automática al modelo local si el remoto no responde.